TECHNICAL APPLICATIONS AND DATA MANAGEMENT. WS 2021/2022.

VORLESUNG 7

26.10.2021

MÜNCHEN

STUDIENGANG DIGITAL MANAGEMENT.

AGENDA

1. Einführung Neuronale Netze/ Deep Learning
2. Convolutional Neural Networks
3. Transfer Learning
4. Fallbeispiel: Erkennen Malariainfizierte Zellen
5. Case Study: Fashion MNIST

WAS HABEN WIR BIS JETZT GEMACHT?

ROADMAP	WAS HABEN WIR GEMACHT?
Vorlesung 1	Workflow Data Management, Datentypen und Datenqualität
Vorlesung 2	Einführung Data Science und Data Science Workflow, Grundlagen Data Management
Vorlesung 3	Grundlagen Stochastik: Wahrscheinlichkeitsrechnung, deskriptive und explorative Statistik
Vorlesung 4	Statistische Inferenz, lineare Regression
Vorlesung 5	Einführung Machine Learning, Unüberwachtes Lernen
Vorlesung 6	Überwachtes Lernen

1. NEURONALE NETZWERKE

ÜBERSICHT NEURONALE NETZE.

Ziel: Wir suchen ein Modell, um für beliebige Eingaben X eine Zielgröße Y möglichst genau zu bestimmen oder anzunähern.

Ermöglicht:

- Regression: Vorhersage kontinuierlicher Wert für Y (bspw. natürliche oder reelle Zahl)
- Klassifikation: Vorhersage diskreter Wert für Y (bspw. Wahr/ Falsch, Tierart, Personenentdeckung, ….)
- Neu: Erkennen von Bildinhalten (CNN) und zeitabhängigen Daten (RNN)

Alles bisher bekannt…

Was schauen wir uns?

- Convolutional Neural Networks
- Transfer Learning
- ~~Regression~~
- Rekurrente Neuronale Netze (nächste Woche)

Neuronale Netze können mit großen bis sehr großen Datenmengen besser umgehen als die bisher in der Vorlesung betrachteten Verfahren. Dafür sind sie komplexer und benötigen länger zum Trainieren. Zudem ist die Erklärbarkeit der Ergebnisse nicht ganz einfach.

ARTEN NEURONALER NETZE.

- „einfache“ neuronale Netzwerke für Regression/ Klassifikation.
- Convolutional Neural Networks (CNN)/ gefaltete neuronale Netzwerke: Top-Methode für Bilderkennung.
  - Einfache CNN („Vanilla CNN“).
  - Transfer Learning: Nehmen und Anpassen vortrainierter CNN-Netzwerke.
- Rekurrente Neuronale Netzwerke: zeitabhängige Daten wie Sprache, Börsenkurse, … spätere Vorlesung

Alle drei Varianten haben prinzipiell die gleiche Struktur, CNN und RNN setzen auch „normale“ Neural Networks ein.

ÜBERSICHT EINFACHES NEURONALES NETZ (MULTILAYER PERCEPTRON).

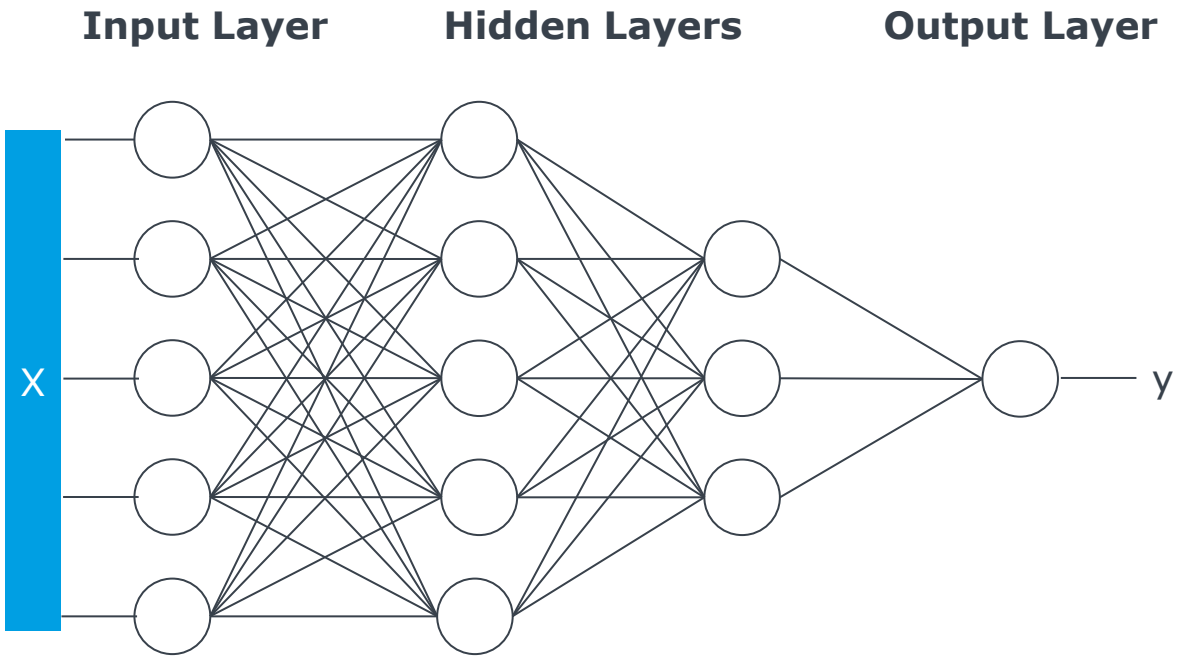

Der Input Layer wird bei der Anzahl der Layer meist nicht mitgezählt. Ein neuronales Netz mit mindestens 1 Hidden Layer wird **Deep Learning Network** genannt.

- **Input Layer:** Erhält Eingaben **X** und reicht diese direkt an Hidden Layer weiter. Keine Datenumwandlung/-bearbeitung! Der Input Layer skaliert mit/ bildet die Eingabegröße ab (bspw. Anzahl Pixel eines Bildes, ….).
- **Hidden Layer:** hier werden die Daten durch die einzelnen Zellen/ **Nodes** transformiert. Durch Verwenden mindestens eines Hidden Layers können beliebig komplexe Funktionen abgebildet bzw. angenähert werden[1].
- **Connections**: Verbindungen zwischen einzelnen Elementen der Layer. Ist ein Layer mit allen Elementen des vorherigen und nachherigen Layer verbunden, spricht man von einem **fully connected layer.**
- **Output Layer:** letzte Layer. Generiert das finale Ergebnis **y**. Anzahl entspricht dem zu prädizierenden Ergebnis (bspw. 1 für Erkennen Hund/ Katze oder 10 bei Ziffern).

Eingaben X für den Input Layer werden durch die Nodes der Hidden Layers sowie des Output Layer so umgewandelt, daß die Zielgröße y möglichst genau bestimmt oder angenähert wird (Fallbeispiel Malaria: Input-Bild wird klassifiziert)

Quellen:
1 Lippmann: "An introduction to computing with neural nets", 1987 sowie Cybenko: "Approximation by superposition of a sigmoidal function", 1989.

DETAILLIERUNG NODE/ PERCEPTRON.

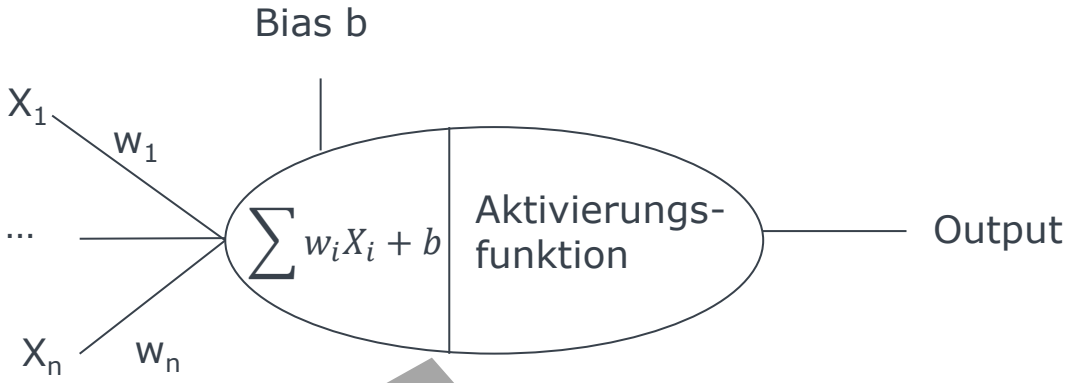

Der Name neuronales Netz stammt von der Ähnlichkeit eines Perceptrons zu einem Neuron im Gehirn. Beide funktionieren aber unterschiedlich.

- **Weights:** jeder Input hat ein Gewicht, das angibt, wie stark der Einfluß des Inputs auf den Node ist.
- **Bias:** stellt Aktivierung Node auch bei Inputs = 0 sicher. (vgl. Geradengleichung mx + t für x=0).
- **Aktivierungsfunktion[1]:** verarbeitet die Gewichte w, Eingaben X_i und Bias b. Ermöglicht Abbilden komplexer Beziehungen zwischen Input und Output.
  Meist setzen wir eine der folgenden Funktionen ein:

Rectified Linear Unit (ReLU)[2]

Empfehlung für Hidden Layers

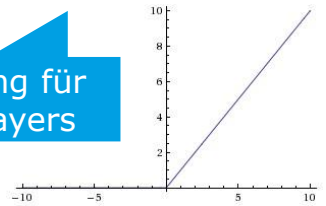

Sigmoid

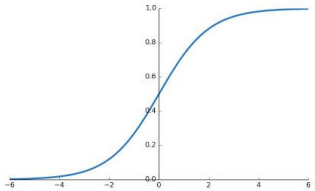

SoftMax

Gibt aber noch mehr, bspw. tanh

Weights und Bias sind die Parameter, die im Training gelernt werden, um die Zielgröße/n anzunähern.

1 Funktion sollte:
- Kont. Differenzierbar/ keine Lücken haben, da sonst Gradient Descent nicht funktioniert
- begrenzte Wertemenge (meist zwischen 0 und 1) haben, damit Gradient Descent stabiler ist
- nicht linear sein, um komplexere Funktionen als Geraden abzubilden. Aber: ReLU funktioniert sehr gut!

Quellen: 2 Nair, V. & Hinton, G.: "Rectified linear units improve restricted Boltzmann machines". ICML, 2010.

DETAILLIERUNG NODE/ PERCEPTRON.

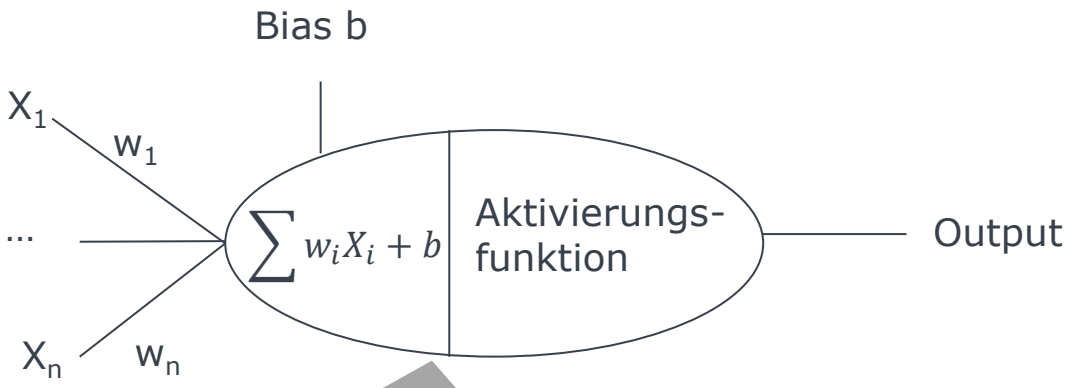

Der Name neuronales Netz stammt von der Ähnlichkeit eines Perceptrons zu einem Neuron im Gehirn. Beide funktionieren aber unterschiedlich.

- **Weights:** jeder Input hat ein Gewicht, das angibt, wie stark der Einfluß des Inputs auf den Node ist.
- **Bias:** stellt Aktivierung Node auch bei Inputs = 0 sicher. (vgl. Geradengleichung mx + t für x=0).
- **Aktivierungsfunktion[1]:** verarbeitet die Gewichte w, Eingaben X_i und Bias b. Ermöglicht Abbilden komplexer Beziehungen zwischen Input und Output.
  Meist setzen wir eine der folgenden Funktionen ein:

Rectified Linear Unit (ReLU)[2]

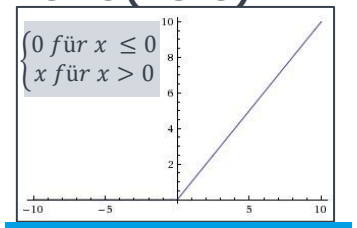

Empfehlung: für Hidden Layer nehmen

Sigmoid

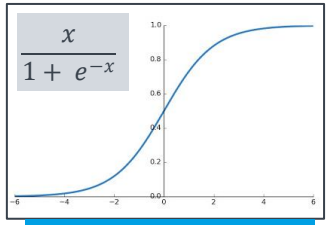

Für Hidden Layer

SoftMax

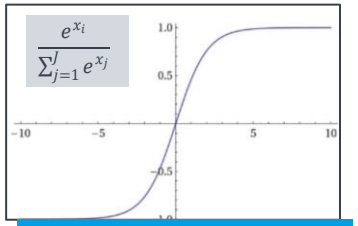

Für Klassifikation im letzten Layer

Weights und Bias sind die Parameter, die im Training gelernt werden, um die Zielgröße/n anzunähern.

1 Funktion sollte:
- Kont. Differenzierbar/ keine Lücken haben, da sonst Gradient Descent nicht funktioniert
- begrenzte Wertemenge (meist zwischen 0 und 1) haben, damit Gradient Descent stabiler ist
- nicht linear sein, um komplexere Funktionen als Geraden abzubilden. Aber: ReLU funktioniert sehr gut!

Quellen: 2 Nair, V. & Hinton, G.: "Rectified linear units improve restricted Boltzmann machines". ICML, 2010.

TRAINING VON NEURONALEN NETZEN

1. Feed Forward: Vorhersage Wert je **Sample** (individuelle Zeile Datensatz).

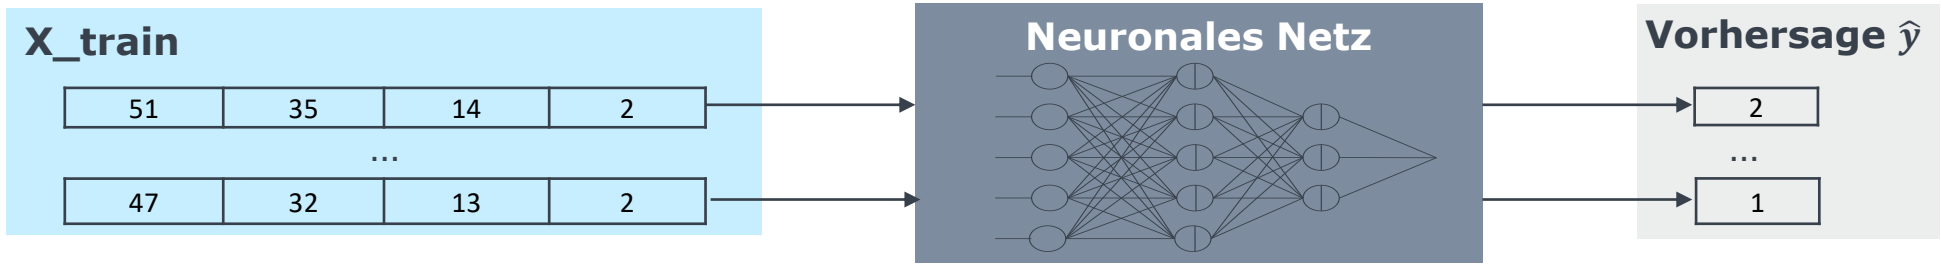

2. Berechnen Modellgüte und Fehler des Modells

- **Loss Function:** Berechnen Delta zwischen realem und vorhergesagtem Wert.
- **Cost Function:** Durchschnitt der Losses für jedes Sample des Trainingsset.

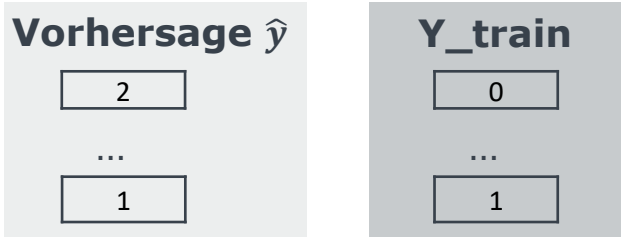

3. Minimierung Fehler und Anpassen Modellparameter:

- Aufstellen Gleichung für Minimierung Cost Function.
- Lösen Gleichung für die Modellparameter per Gradient Descent[1].
- Aktualisierung Modellparameter per **Backpropagation**[2].

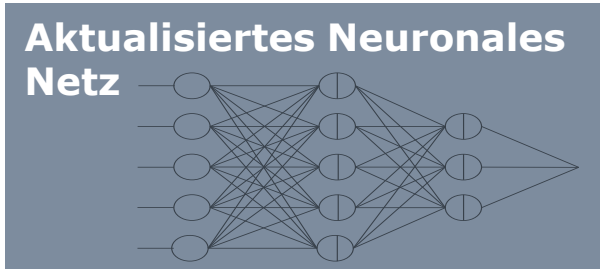

Durchführen Schritte 1-3 inkl. Update Modellparameter für gesamtes Trainingsset heißt **Epoch**, für Teile Trainingsset **Batch.** Anzahl Durchläufe je Batch/ Epoch erfahrungsabhängig inkl. Abbruchkriterien (ausreichende oder stagnierende Güte)

Quellen: 1 Gradient Descent: Hadamard, J.: "Memoire sur le problème d'analyse relatif a l`equilibre des plaques 'elastiques' encastrees", 1908. Zuerst eingesetzt für Cost Function durch Dreyfus, S. E.: "The computational solution of optimal control problems with time lag", 1973.
2 Linnainmaa, S.: "The representation of the cumulative rounding error of an algorithm as a Taylor expansion of the local rounding errors", 1970. Erster Einsatz in NN: Werbos, P.: "Applications of advances in nonlinear sensitivity analysis". In Proceedings of the 10th IFIP Conference, 1981.

DIE ANPASSUNG DER PARAMETER DES NEURONALEN NETZES ERFOLGT DURCH GRADIENT DESCENT.

2 Möglichkeiten für Berechnen globales Minimum[1]:
1. Lösen Gleichung Cost-Fkt J(w) = 0 für alle Gewichte/ Bias
2. Iteratives Verfahren Gradient Descent

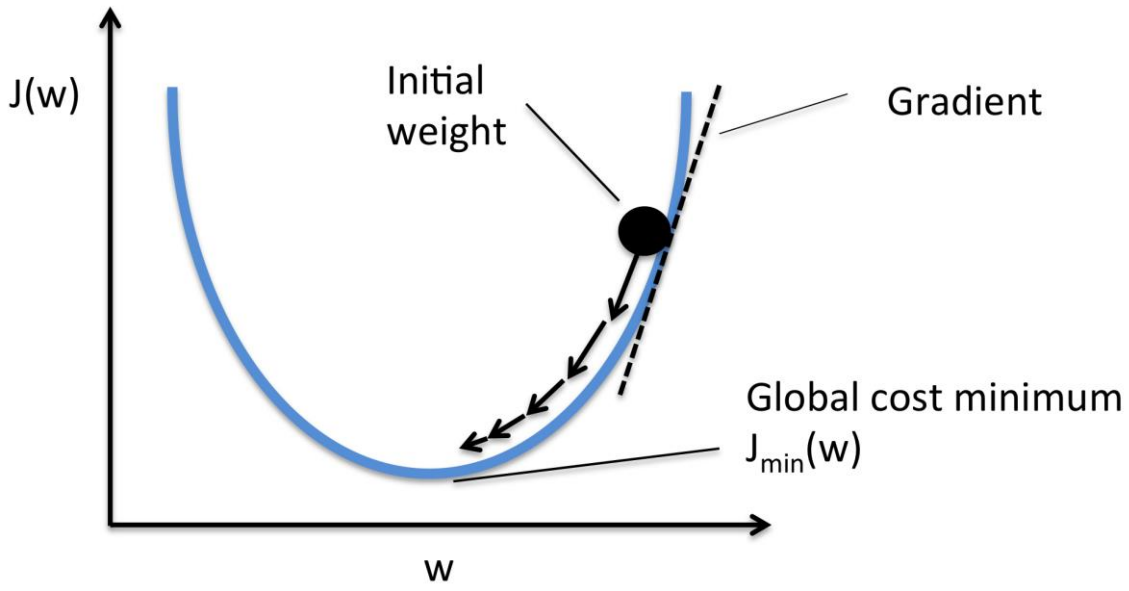

Ablauf Gradient Descent Algorithmus:

1. Initialisiere zufällig gewählte Gewichte w sowie Bias b.
2. Iteriere über alle Parameter:
   1. Feed-Forward: Berechne $\hat{y}$ (prädizierter Wert).
   2. Berechne Loss-Funktion J(w) für w und b.
   3. Berechne Gradienten, d.h. ziehe von w und b ein kleines Delta η*w und η*b ab → **Graduelles Absteigen!** Dieses η ist die **Lernrate,** ein wichtiger **Hyperparameter**.
3. Gehe zu 2 solange bis sich Loss nicht mehr signifikant ändert.

Ziel Algorithmus: iteratives Wählen von Werten für Gewichte und Bias, um Cost-Funktion so weit wie möglich zu minimieren. Ein iteratives Verfahren ist weniger rechenaufwendig als die Alternative Einsetzen aller Parameter.

Quelle Bild: Link
1 Bestimmen globales Minimum einer Funktion erfolgt über Bilden erste Ableitung und gleich 0 setzen.

FALLBEISPIEL KLASSIFIKATION ANHAND GROSSER DATENSÄTZE ZEIGT VORTEILE NEURONALER NETZE.

Zufällig generiertes Dataset mit 50‘000 Zeilen und 20 Features:

Algorithmus	**Genauigkeit** (ohne GPU)	**Dauer Training** (ohne GPU)
Logistische Regression	0.938	296 ms
XGBoost	0.966	5.86 s
Neuronales Netz (nur 20 Epochen)	0.968	1 min 11 s

Zufällig generiertes Dataset mit 500‘000 Zeilen und 30 Features:

Algorithmus	**Genauigkeit** ohne GPU/ Mit GPU	**Dauer Training** ohne GPU/ Mit GPU
Logistische Regression	0.90 0.932	2,4 s 2,14 s
XGBoost	0.913 0.943	1,46 min 1,33 min
Neuronales Netz (nur 20 Epochen)	0.92 0.955	14 min 22 min

Bei großen bis sehr großen Datenmengen bietet Neuronales Netz sehr gute Performance bei hoher Trainingszeit

1 Gestoppt in Google Colab ohne Grafikkarte(Abkürzung GPU). Grafikkarten beschleunigen Training enorm, da ihre vielen arithmetischen Recheneinheiten die notwendigen Matrizenmultiplikationen parallel rechnen können statt im Prozessor, der weniger solcher Recheneinheiten hat und deshalb sequentiell berechnet.

2 GEFALTETE NEURONALE NETZWERKE (CNN)

CONVOLUTIONAL NEURAL NETWORK: MOTIVATION.

Bei einer Klassifikation von Bildern haben wir 2 grundlegende Probleme:

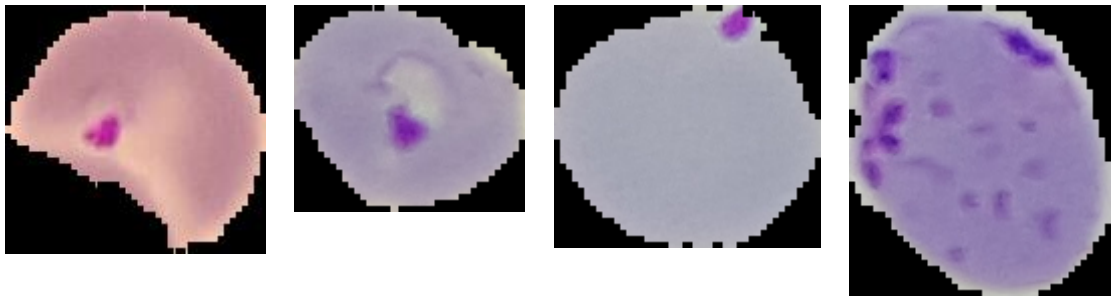

Gleiche Objekte, aber verschiedene Darstellungen. Die bisher vorgestellten Verfahren würden die Pixel lernen, was nicht funktionieren würde.

1. Bilder können sich stark unterscheiden:
   - Größe
   - Ausrichtung: Quer- vs. Hochformat, gedrehtes Bild
   - Farben
   - Belichtung
   - …
2. Bilder sind enorm groß verglichen mit Text und Zahlen: Kamerabilder haben 16 Mio. Punkte!

Convolutional neural networks lernen Formen und Strukturen (Features) in Bildern.

Quellen:
Bilder Zellen: National Library of Medicine: Malaria Dataset, Link
Bilder Labradore: Wikipedia-Artikel

CNN SETZT FALTUNGEN FÜR ERKENNEN VON STRUKTUREN IN BILDERN EIN.

Löschen nicht vert. Linien durch 0-Werte diese Spalte

Filter

1	0	-1
2	0	-2
1	0	-1

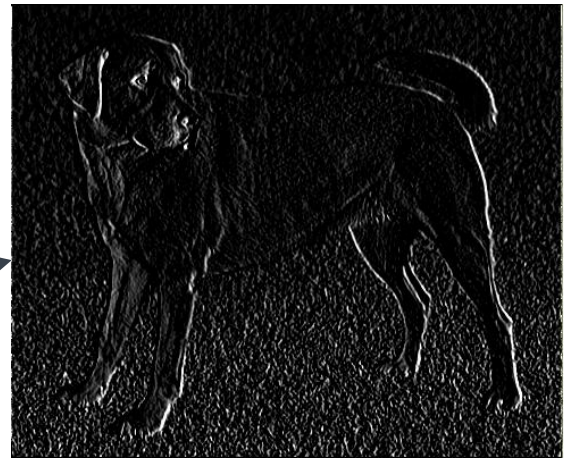

„Entdecken" vertikaler Linien

Filter

-1	-2	-1
0	0	0
1	2	1

Löschen nicht horiz. Linien durch 0-Werte dieser Zeile

„Entdecken" horizontaler Linien

Die Faltung geschieht indem rollierend Zeile für Zeile jeweils mit einem Filter multipliziert werden

Quelle: Link, Link

CONVOLUTIONAL NEURAL NETWORK. WIE FUNKTIONIERT DAS LERNEN?

Bild mit seinen 3 Farbkanälen Rot, Grün, Blau wird mit Filter multipliziert (Faltung).
Dimension Filter ist ungerade, um Symmetrien zu vermeiden.

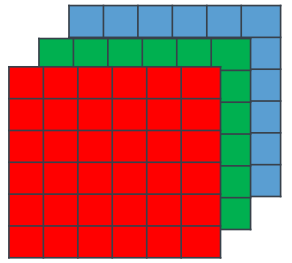

Bild mit 3 Farbkanälen

*

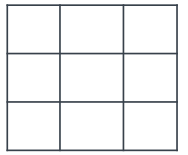

3x3 Filtermatrix

Filter durchläuft analog Lupe Zeile für Zeile des Bildes.
Ergebnis wird in separater, verkleinerter Matrix gespeichert

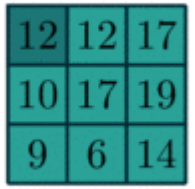

Ziel ist es, durch mehrere kombinierte Faltungen nacheinander das Bild auf die wichtigsten Informationen zu reduzieren.

Quelle Bilder/ Animation: Link

CONVOLUTIONAL NEURAL NETWORK. PADDING UND STRIDING

Padding: ist die Breite oder Höhe des Bildes nicht genau durch die Höhe oder Breite des Filters teilbar, bleibt Rest über. Padding ermöglicht:

- **Padding = 0:** Rest abzuschneiden, Rand wird „ignoriert" vom Filter.
- **Padding = n:** jeweils n Zeilen/ Spalten mit Zahl 0 werden an den Rand hinzugefügt, damit Rand berücksichtigt wird.

Stride: bestimmt die Schrittweite des Filters je Faltung.

Ermöglicht Reduzierung Daten (Kompression).

Frage: welche Schrittweite im Bild? Welches Padding?

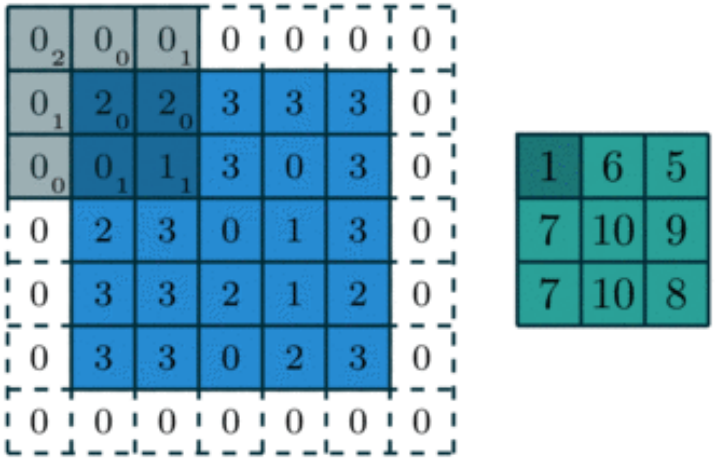

Padding mit 1x1 Grenzzone und Stride = 2

Padding und Stride sind Standardparameter jeder Faltung. Für die meisten Fälle reichen die Default-Werte für beide Parameter.

Quelle Bilder/ Animation: Link

CONVOLUTIONAL NEURAL NETWORKS: ZUSAMMENSPIEL DER FALTUNGSOPERATOREN.

https://poloclub.github.io/cnn-explainer/

CONVOLUTIONAL NEURAL NETWORK. POOLING.

1	4	3	12
8	9	7	4
3	9	2	1
15	13	3	7

Max-Pooling mit 2x2 Filter und Stride = 2

9	?
?	7

Frage: was kommt hier rein?

Pooling ermöglicht Reduzierung Daten, Entfernen von Rauschen und verhindert Overfitting.

CONVOLUTIONAL NEURAL NETWORK. DROPOUT.

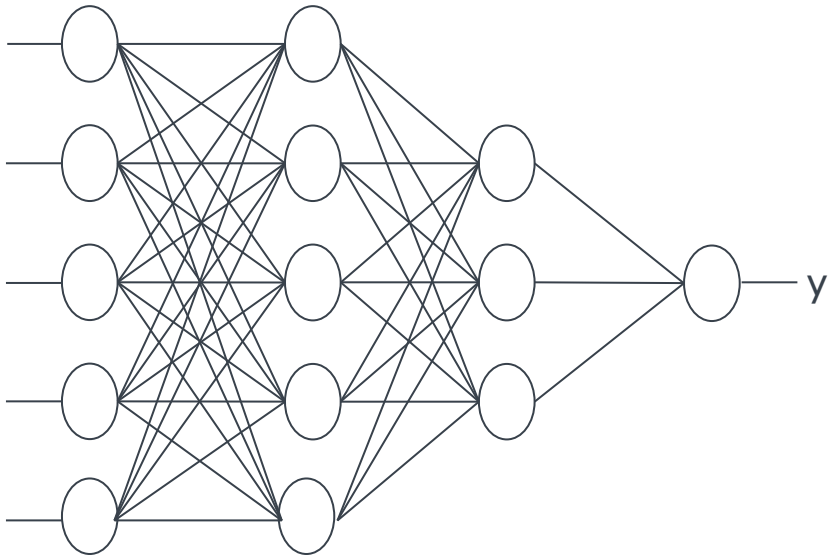

tf.keras.layers.Dropout(0.5)

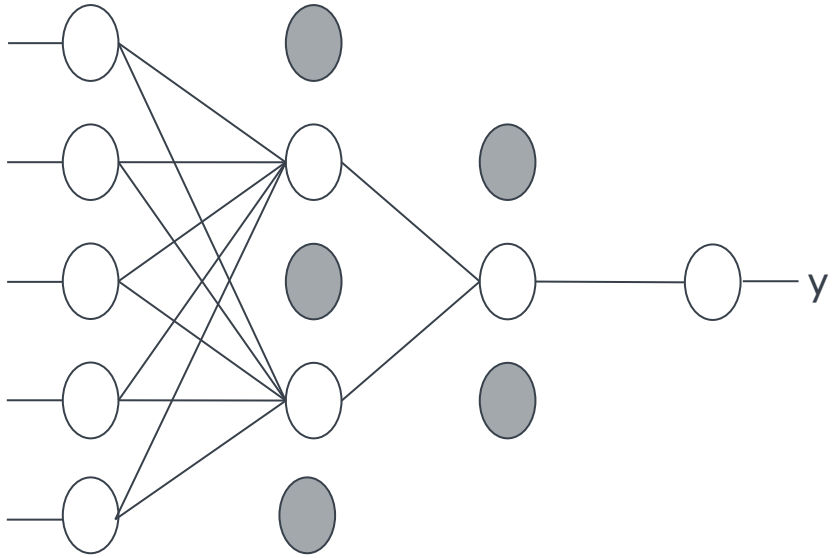

Fully-connected ANN und **CNN** neigen aufgrund Vielfalt an Parametern zu Overfitting

Dropout schaltet jeden Knoten mit Wahrscheinlichkeit 1-p als „passiv". In jedem Trainingsdurchlauf werden andere Knoten passiv geschalten (hier: 50% Knoten).

Dropout reduziert Overfitting (und beschleunigt das Training).

Quelle: Hanson, S. J.: "A Stochastic Version of the Delta Rule", PHYSICA D,42, 265-272, 1990.

CONVOLUTIONAL NEURAL NETWORKS: KOMBINATION FALTUNGEN UND FEATURES ERMÖGLICHT LERNEN KOMPLEXER FEATURES.

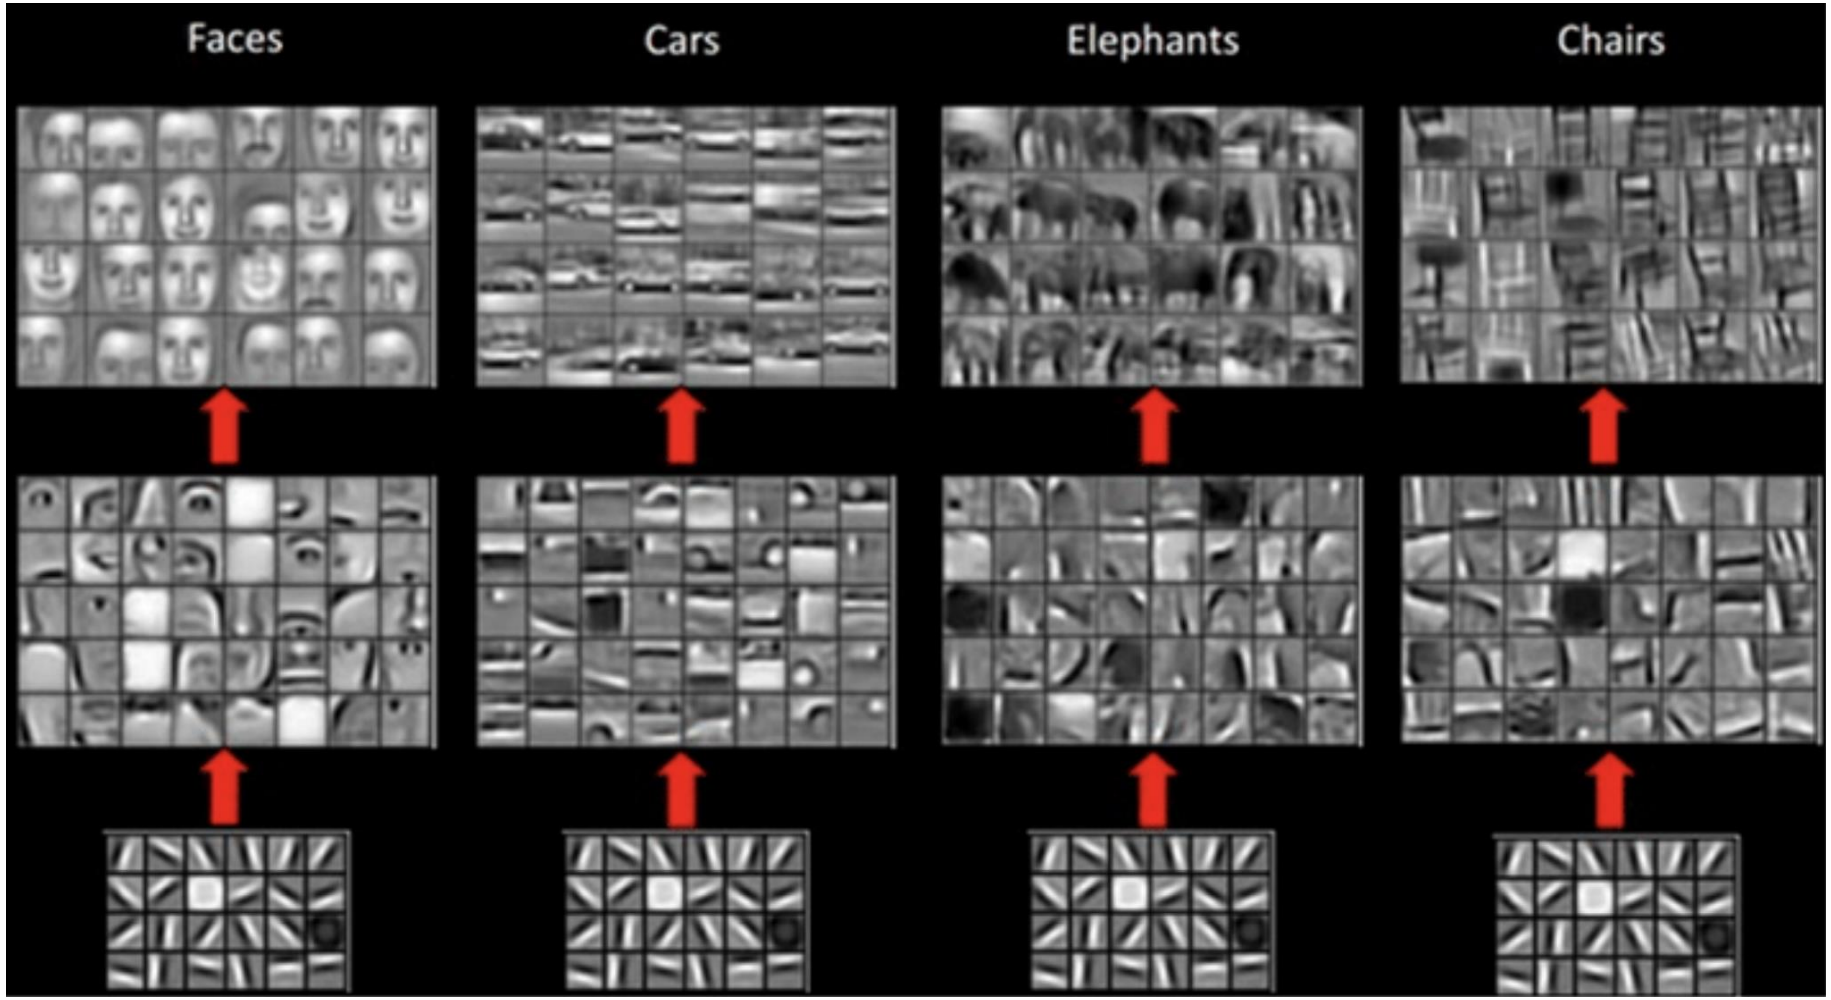

Quelle: Link

KOPPLUNG CNN MIT NEURONALEN NETZEN.

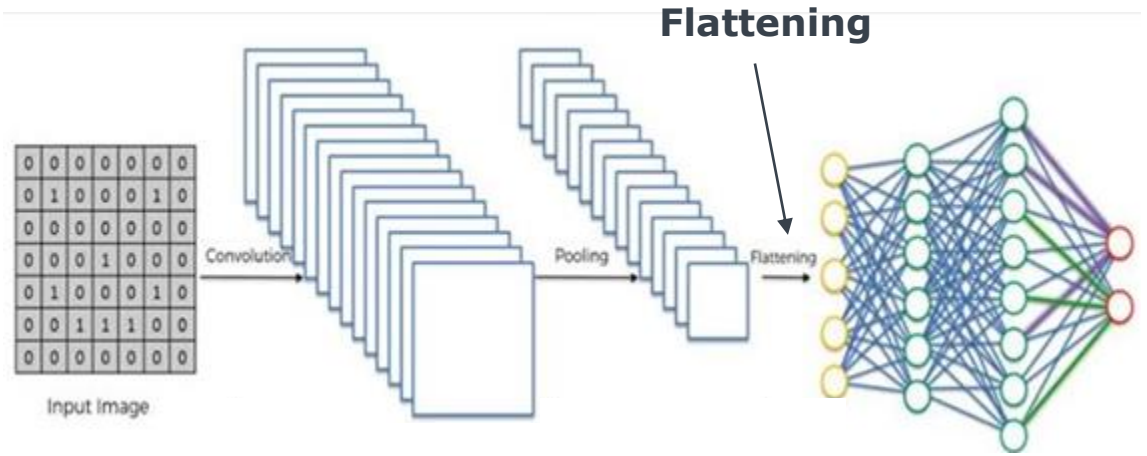

- Wir haben gesehen, wie Features in Bildern gelernt werden.
- Aber: für Klassifizieren Bilder fehlt noch Output-Vektor. Dies geschieht durch Verknüpfen mit einem „einfachem" neuronalen Netz.
- Verknüpfung erfolgt, indem das Bild so aufbereitet wird, daß es einen linearen Eingabevektor darstellt.
- Dies geschieht durch den **Flatten**-Operator. Er speichert die gelernten Features des Bildes als 1-dimensionalen Vektor.
- Weitere Vorgehensweise analog „einfachem" neuronalen Netz oder den bisher gelernten Verfahren.

Nach dem Lernen/ Extrahieren der relevanten Features aus dem Bild, werden diese Features per „Flatten" Eingaben für ein normales neuronales Netz.

Quelle: Link

CONVOLUTIONAL NEURAL NETWORK: ÜBERSICHT GESAMTABLAUF.

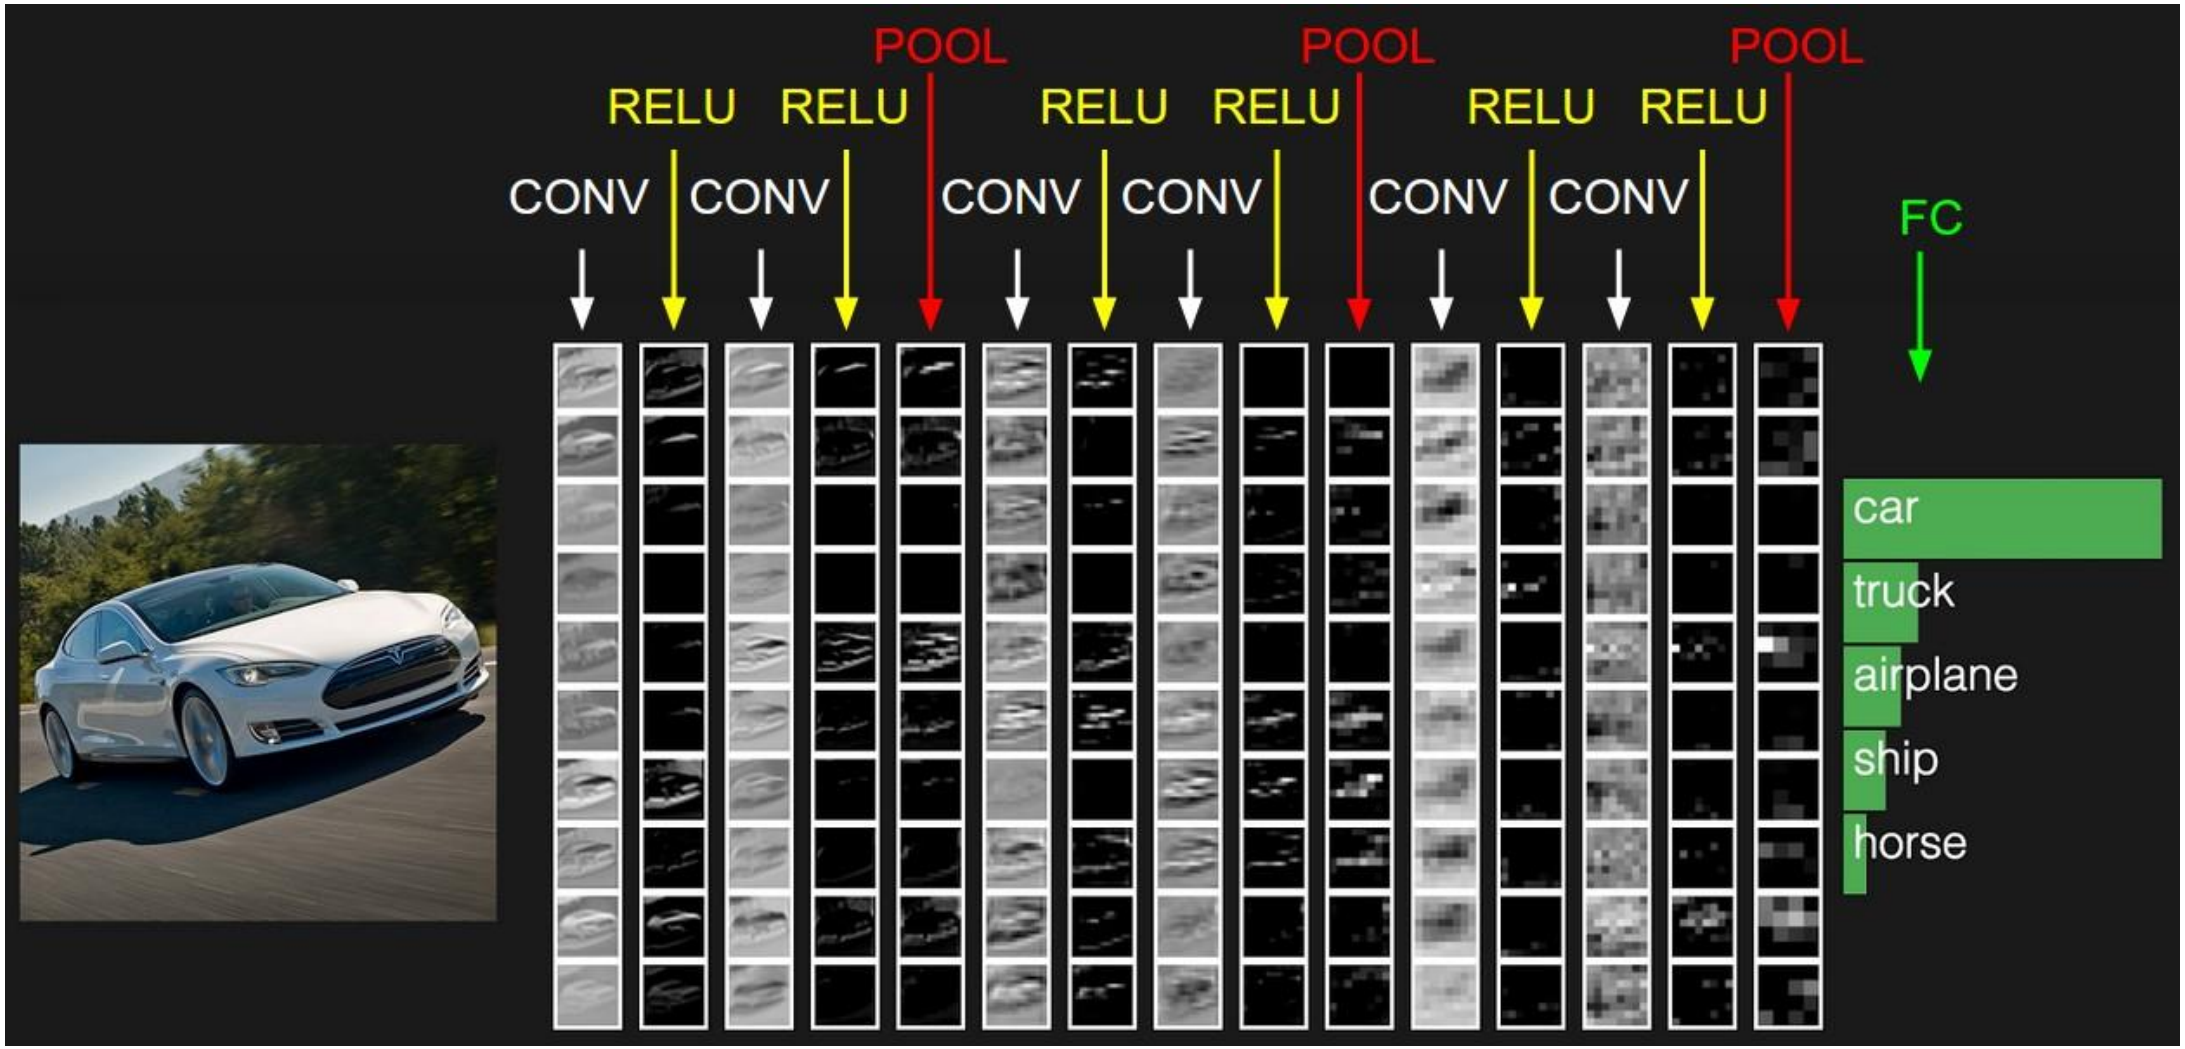

Quelle: Link

CONVOLUTIONAL NEURAL NETWORKS – LIVE DEMOS IM BROWSER.

https://cs.stanford.edu/people/karpathy/convnetjs/demo/mnist.html

http://cs231n.stanford.edu/2019/

2. TRANSFER LEARNING.

TRANSFER LEARNING.

Transfer Learning bedeutet **Übernahme** und ggf. **Anpassen** eines **bereits trainierten Modells**.

Vorteile:

- Schnell einsetzbar.
- Modelle wurden lang auf sehr großen Daten trainiert und haben somit validierte, gute Performance.

Nachteile:

- Nur für ähnliche Probleme einsetzbar.
- Anpassungen am Netz mit Vorsicht durchzuführen (vorgelernte Features können geändert/ gestört werden).

Einsatzgebiete:

- Bilderkennung
- Spracherkennung
- Übersetzung

ÜBERSICHT NETZE UND IHRER PERFORMANCE.

Model	Size (MB)	Top-1 Accuracy	Top-5 Accuracy	Parameters	Depth	Time (ms) per inference step (CPU)	Time (ms) per inference step (GPU)
Xception	88	0.790	0.945	22,910,480	126	109.42	8.06
VGG16	528	0.713	0.901	138,357,544	23	69.50	4.16
VGG19	549	0.713	0.900	143,667,240	26	84.75	4.38
ResNet50	98	0.749	0.921	25,636,712	-	58.20	4.55
ResNet101	171	0.764	0.928	44,707,176	-	89.59	5.19
ResNet152	232	0.766	0.931	60,419,944	-	127.43	6.54
ResNet50V2	98	0.760	0.930	25,613,800	-	45.63	4.42
ResNet101V2	171	0.772	0.938	44,675,560	-	72.73	5.43
ResNet152V2	232	0.780	0.942	60,380,648	-	107.50	6.64
InceptionV3	92	0.779	0.937	23,851,784	159	42.25	6.86
InceptionResNetV2	215	0.803	0.953	55,873,736	572	130.19	10.02
MobileNet	16	0.704	0.895	4,253,864	88	22.60	3.44
MobileNetV2	14	0.713	0.901	3,538,984	88	25.90	3.83
DenseNet121	33	0.750	0.923	8,062,504	121	77.14	5.38
DenseNet169	57	0.762	0.932	14,307,880	169	96.40	6.28
DenseNet201	80	0.773	0.936	20,242,984	201	127.24	6.67
NASNetMobile	23	0.744	0.919	5,326,716	-	27.04	6.70
NASNetLarge	343	0.825	0.960	88,949,818	-	344.51	19.96
EfficientNetB0	29	-	-	5,330,571	-	46.00	4.91
EfficientNetB1	31	-	-	7,856,239	-	60.20	5.55
EfficientNetB2	36	-	-	9,177,569	-	80.79	6.50
EfficientNetB3	48	-	-	12,320,535	-	139.97	8.77
EfficientNetB4	75	-	-	19,466,823	-	308.33	15.12
EfficientNetB5	118	-	-	30,562,527	-	579.18	25.29
EfficientNetB6	166	-	-	43,265,143	-	958.12	40.45
EfficientNetB7	256	-	-	66,658,687	-	1578.90	61.62

Erklärung Parameter:

- **Size:** Größe des zu speichernden Modells. Relevant für den Einsatz auf Geräten mit beschränktem Speicherplatz wie z.B. Handys oder IoT-Geräten.
- **Top-1 Accuracy:** gibt an, wie oft auf Daten des ImageNet-Datensatz genau die richtige Klasse erkannt wurde.
- **Top-5 Accuracy:** gibt an wie oft auf Daten des ImageNet-Datensatz eine von 5 gleichzeitigen Vorhersagen des Modells die richtige war.
- **Parameters:** Anzahl Parameter. Relevant falls das Modell angepaßt wird, da dies ein Indikator für die benötigte Rechenleistung und somit Dauer des Trainings ist.
- **Depth**: Tiefe des Netzes mit allen seinen Schichten.
- **Time per inference step**: wie lang Netz für die Inferenz braucht (also Auswertung Input in Netz).

ImageNet-Wettbewerb ist Benchmark für Bildererkennung

Kein Modell ist perfekt, Wahl ist abhängig vom jeweiligen Einsatzgebiet und Ressourcen

Quelle: Link

TRANSFER LEARNING: WIE SETZEN WIR ES EIN?

Möglichkeit A: Direktes Verwenden Netz

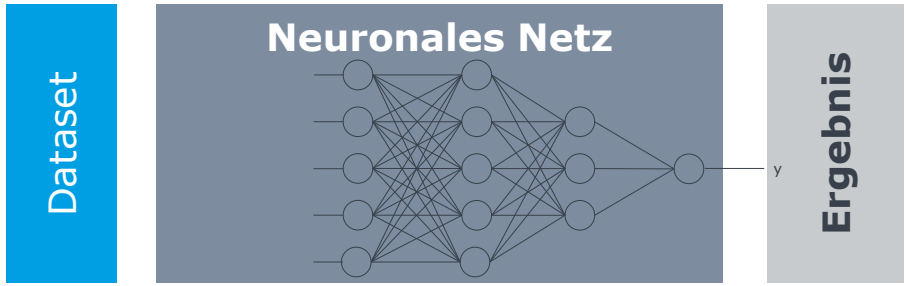

Einsatz für Standardanwendungsfall,
keine Änderungen notwendig.

Möglichkeit B: Anpassen/ Ersetzen spezifischer Netzumfänge

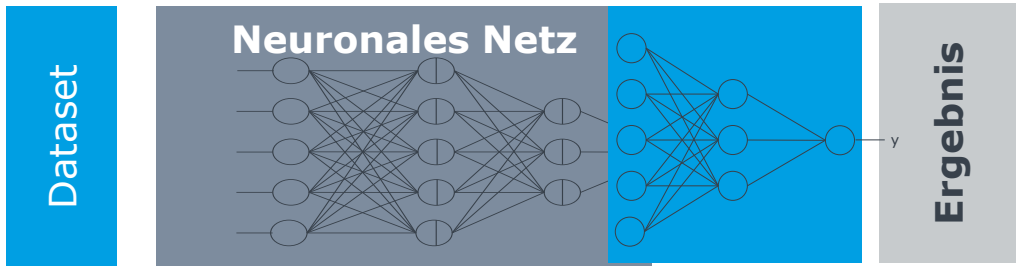

Änderungen notwendig, bspw. aufgrund geänderter Zielklassen.
Angepasst werden die letzten Schichten des Modells.

BEISPIEL FÜR TRANSFER LEARNING: ALEXNET IN 2012.

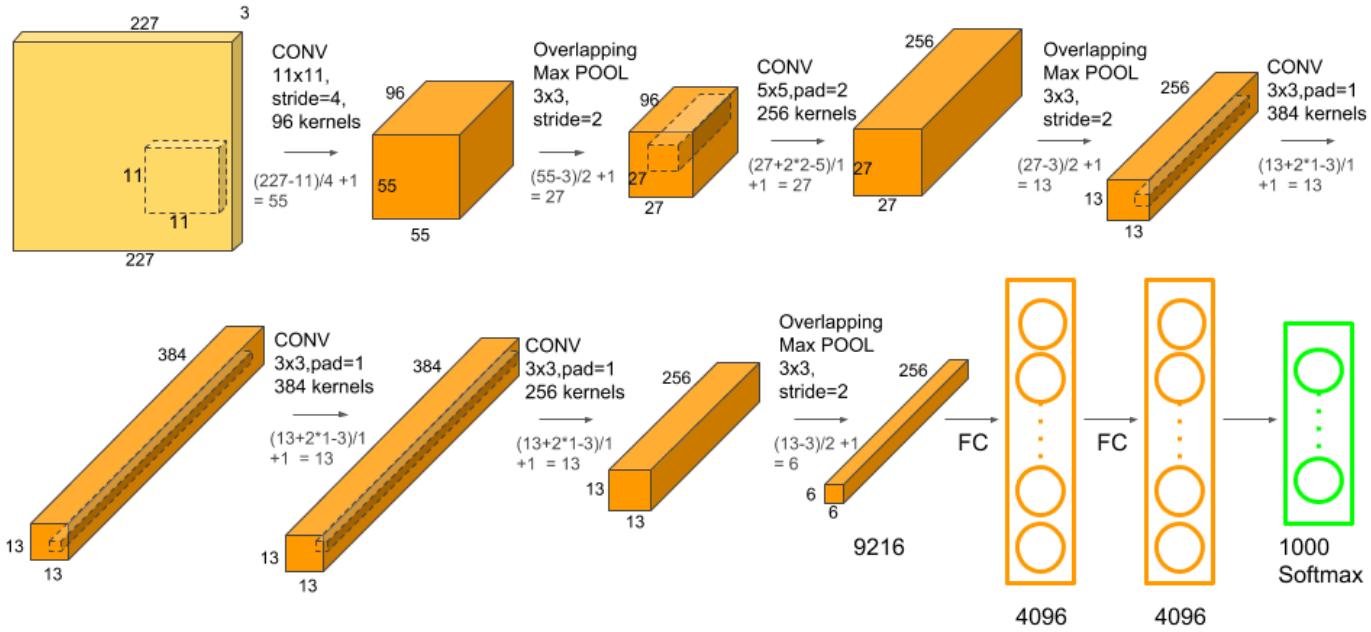

- Eines der einflußreichsten Paper in Computer Vision, ca. 70 000 mal zitiert.
- „Startschuß" für verstärkten Einsatz GPU.
- Aber: Dan-Net nutzte vorher schon GPU, und war mit seinen Weiterentwicklungen auch besser als AlexNet. Es ist aber weniger bekannt...

Quellen:
Krizhevsky, Sutskever, Hinton: „ImageNet Classification with Deep Convolutional Neural Networks", 2012.
Bild: Link
Ciresan, D. Meier, U., Gambardella, L. M., Schmidhuber, J.: „Deep Big Simple Neural Nets For Handwritten Digit Recognition", Neural Computation 22(12): 3207-3220, 2010.

BEISPIEL FÜR TRANSFER LEARNING: RESNET- 2015.

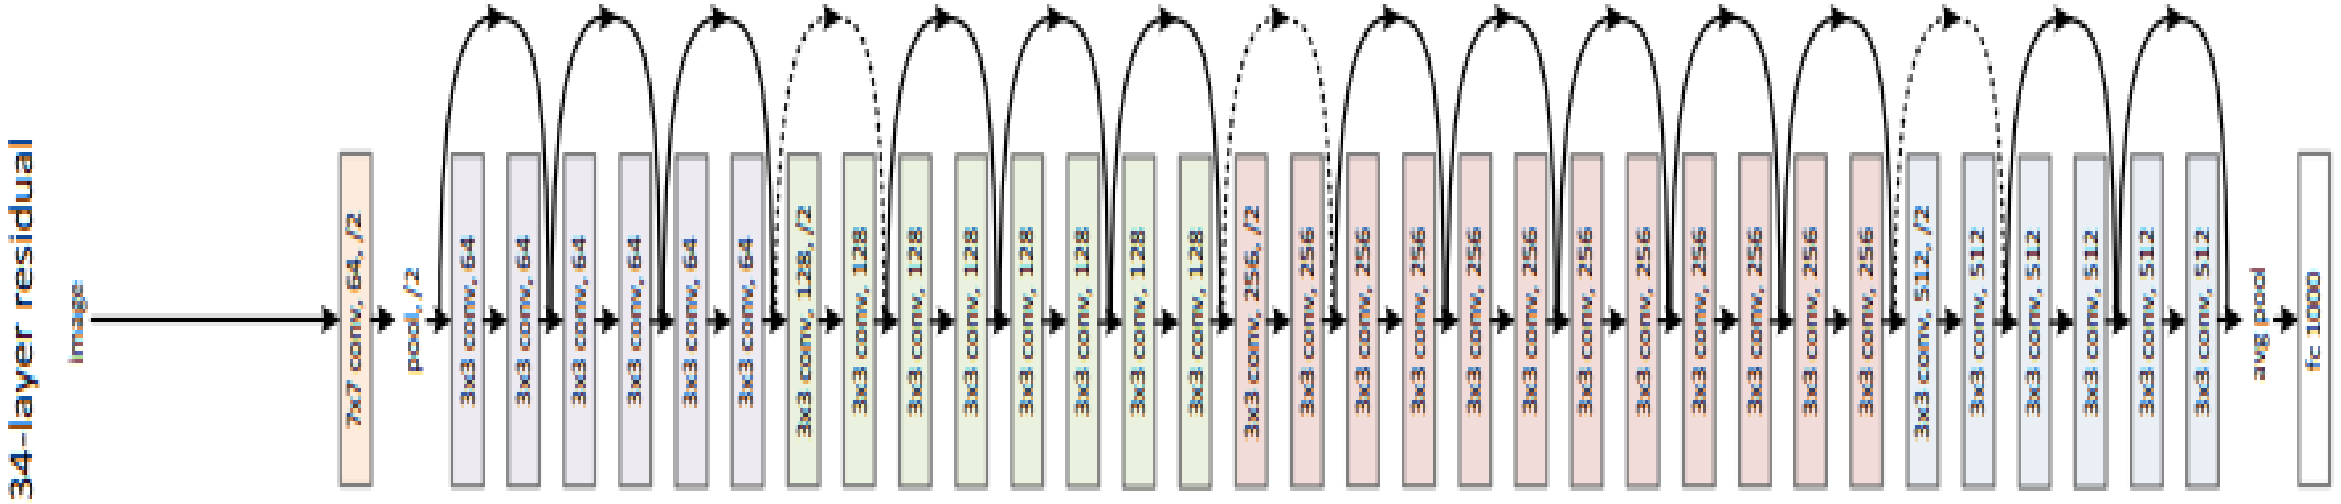

Quelle: He, Zhang, Ren, Sun (2015): Deep Residual Learning for Image Recognition

4. CASE STUDY

CASE STUDY IN GRUPPENARBEIT

1. Erstellen Sie ein Notebook in Google Colab.
2. Laden Sie die Datei CNN mit Fashion MNIST-v2.ipynb (liegt auf Github).
3. Probieren Sie verschiedene CNN-Strukturen aus: wie ändert sich dabei die Genauigkeit des Modells?
   - Passen Sie die bestehenden Conv2D-Faltungen an bzgl. Anzahl Filter, Kernel, Padding, Aktivierungsfunktionen.
   - Bauen Sie eine/ mehrere neue Faltungen (Conv2D) ein.
   - MaxPooling2D: Experimentieren Sie mit der Größe des Pooling.
   - Dropout: Experimentieren Sie mit dem Prozentwert.
   - Passen Sie die bestehende Dense-Layer an.
   - Bauen Sie neue Dense-Layer ein.
4. Probieren Sie verschiedene Hyperparameter aus: wie ändert sich dabei die Genauigkeit des Modells?
   - BATCH_SIZE
   - EPOCHS
   - LEARNING_RATE
   - Optimizer: Adam, RSMProp, Adagrad, Stochastic Gradient Descent.
5. Stellen Sie Ihre Ergebnisse, Hypothesen und Plots vor.

30 – 45 Minuten

5. ZUSAMMENFASSUNG

LITERATUR UND WEITERE QUELLEN (AUSZUG).

Künstliche Intelligenz:

- Gröner, Heinecke: Kollege KI
- Burkov: The Hundred-Page Machine Learning Book, online verfügbar unter Link
- Nielsen: Neural Networks and Deep Learning, online verfügbar unter Link
- Russel, Norvig: Artificial Intelligence – a modern approach
- Produktentwicklung mit AI:
  - Ameisen: Building Machine Learning Powered Applications: Going from Idea to Product
  - Ng: Machine Learning Yearning, online verfügbar unter Link

Kostenfreie Online-Kurse (bei Interesse):

- Python-Kurse
  - Python for Everybody (Link)
  - Udacity Python Course (Link)
  - **Coursera Course Deep Learning** (Link)
  - FAST AI (Link)

Web-Links:

- CNN: https://cs231n.github.io/convolutional-networks/
- CNN: https://medium.com/machine-learning-researcher/convlutional-neural-network-cnn-2fc4faa7bb63
- CNN: https://hackernoon.com/everything-you-need-to-know-about-neural-networks-8988c3ee4491
- CNN: https://www.wandb.com/articles/fundamentals-of-neural-networks

BACKUP